# Explicación detallada de resultados

## Sesión 3 · Redes recurrentes y clasificación de reseñas

Juan David Gonzalez · Nelsón Fabian Manios · Sebastian Padilla Castaño

**Resultado:** se eligió TF-IDF + RL por F1 macro de validación. En test obtiene F1 **0.494** y accuracy **50.1%**. El experimento predice una calificación de 1 a 5 estrellas; no identifica emociones o causas anotadas.

## 1. Datos, auditoría y orden de trabajo

Fuente real: SetFit/amazon_reviews_multi_es. El objetivo original label = estrellas - 1 se conserva. Se usa únicamente el texto como entrada; label_text, identificadores y la estrella no son predictores. La revisión fijada es 16015418b488c9186fce74b058877ea939ca934d.

| Partición | Origen | Tras limpieza | Usadas |
|---|---|---|---|
| train | 200000 | 196946 | 20000 |
| validation | 5000 | 4905 | 4905 |
| test | 5000 | 4905 | 4905 |

Se retiraron 2,573 filas con textos idénticos y etiquetas contradictorias, 671 copias adicionales y 0 textos vacíos. Se comprueba que no hay IDs ni textos normalizados exactos compartidos entre las particiones.

El orden es: verificar origen y hashes; validar esquema/nulos/etiquetas; retirar vacíos, conflictos y copias; explorar clases y longitudes; tomar una muestra estratificada de train; aprender representaciones; seleccionar con validación; evaluar test y analizar errores. La limpieza global usa etiquetas para detectar conflictos y modifica el benchmark: no es una prueba completamente intacta del corpus original.

No existen identificadores de producto o autor en esta versión. No se puede garantizar separación por cliente/producto ni ausencia de paráfrasis. Las estrellas aproximan satisfacción, pero no son anotaciones lingüísticas perfectas. Una muestra equilibrada no representa las proporciones naturales de clientes satisfechos.

# 2. Vocabulario, PAD, OOV y longitud

El vocabulario se aprende solo con train. Hay 15,000 posiciones: 0 es PAD, 1 es [UNK]/OOV y las restantes corresponden a palabras. El tokenizador divide por espacios después de limpiar. La longitud elegida es L = 72, usando el percentil 95 de train limitado al intervalo 16-96.

| Concepto | Qué ocurre | Consecuencia |
|---|---|---|
| PAD (0) | Posición vacía añadida al final | Se ignora mediante máscara |
| OOV (1) | Palabra presente sin entrada propia | Se procesa con un vector compartido |
| Padding | Completa hasta L con ceros | Uniforma la forma del lote |
| Truncamiento | Conserva los primeros L tokens | Puede perder una queja al final |

## ¿Por qué no usar todas las palabras?

Un vocabulario ilimitado aumenta memoria y pesos para términos muy raros; una longitud ilimitada aumenta pasos recurrentes y relleno. No se demuestra que más texto empeore: se declara un presupuesto. El costo es convertir términos a OOV y descartar finales. La cobertura mide ese compromiso; los límites alternativos se elegirían con validación, no con test.

| Conjunto | OOV retenidos | Reseñas truncadas | Tokens descartados |
|---|---|---|---|
| train | 1.27% | 4.96% | 5.95% |
| validacion | 2.69% | 4.18% | 5.00% |
| test | 2.72% | 4.75% | 5.83% |

## Cobertura de tokens de entrenamiento

| Límite total | Cobertura | Pesos de embedding |
|---|---|---|
| 2000 | 88.26% | 64000 |
| 5000 | 94.37% | 160000 |
| 10000 | 97.43% | 320000 |
| 15000 | 98.73% | 480000 |
| 22206 | 100.00% | 710592 |

No se eliminan stopwords de forma indiscriminada: «no», «sin» o «pero» pueden cambiar la valoración. Minúsculas y espacios se normalizan; se retiran URLs, HTML y puntuación. Esto también pierde emojis y señales de ironía. La tasa OOV excluye PAD; la tabla distingue texto retenido del texto original.

# 3. Embeddings, masking y redes recurrentes

## Embedding entrenable

Una matriz de 15,000 × 32 convierte IDs en vectores. Son 480,000 pesos que empiezan aleatorios y se ajustan con la pérdida de clasificación. Cada red aprende su propia matriz; no son vectores preentrenados ni 32 emociones interpretables. La comprobación de gradientes usa train y no altera los modelos evaluados.

## Masking

mask_zero=True crea una máscara False en PAD y True en palabras conocidas y OOV. Las capas recurrentes la consumen para omitir relleno. No exige que el vector de PAD sea cero ni recupera tokens truncados. Las cuatro redes superaron la comprobación: añadir siete PAD no cambia las probabilidades más de 1e-5.

## Memoria recurrente y alternativas

| Red | Cómo conserva contexto | Estado final |
|---|---|---|
| SimpleRNN | h(t)=tanh(x(t)Wx+h(t-1)Wh+b); pesos compartidos en cada paso | 32 valores |
| LSTM | Celda de memoria; compuertas de entrada, olvido y salida | 32 valores |
| GRU | Compuertas de actualización y reinicio | 32 valores |
| BiLSTM | Dos LSTM en direcciones opuestas; concatena estados | 64 valores |

SimpleRNN puede perder dependencias largas por gradientes que se desvanecen. clipnorm=1 limita explosiones, pero no resuelve por sí solo ese problema. LSTM y GRU regulan información; BiLSTM usa contexto de ambos sentidos y requiere el texto completo. Ninguno garantiza una mejora de F1.

## Patrón de salida: many-to-one

Muchas palabras producen una única calificación. Flujo: IDs (B,L) → embeddings (B,L,32) → estado (B,32), o (B,64) en BiLSTM → probabilidades (B,5). Las cinco probabilidades son clases alternativas, no cinco momentos. return_sequences=False obtiene el estado final.

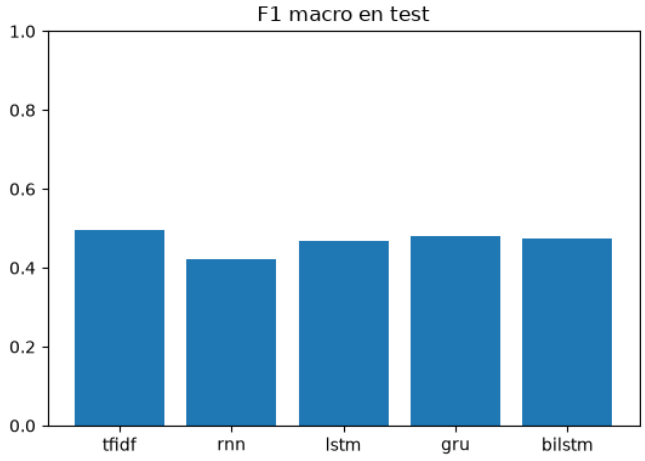
| Patrón | Ejemplo | Aquí |
|---|---|---|
| Many-to-one | Una estrella global por reseña | Sí |
| Many-to-many alineado | Una etiqueta por token | No |
| Sequence-to-sequence | Una secuencia de traducción o resumen | No |

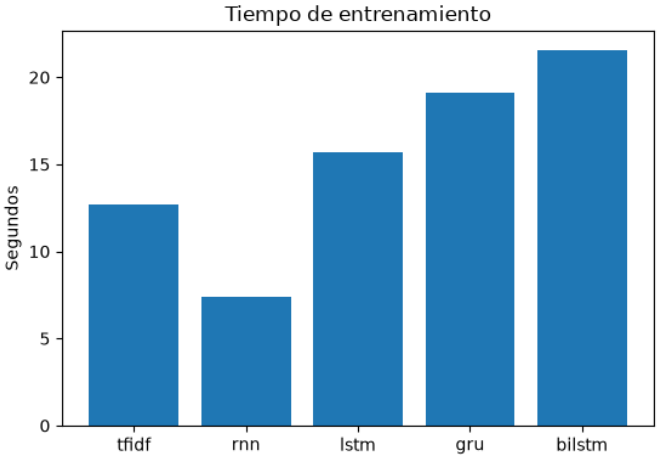
Devolver todos los estados con return_sequences=True no crea por sí solo un decodificador ni aporta etiquetas por palabra.

# 4. Comparación de modelos y criterio de elección

TF-IDF usa unigramas y bigramas (hasta 30.000 rasgos) y regresión logística con C en {0,5; 2}. Las redes comparten embeddings y unidades de tamaño 32, dropout 0,25, lotes de 128, Adam 0,001 y hasta ocho épocas. La parada temprana recupera la menor pérdida de validación; la selección entre modelos usa F1 macro de validación.

| Modelo | F1 val. | F1 test | Accuracy | MAE | Tiempo (s) |
|---|---|---|---|---|---|
| TF-IDF + RL | 0.479 | 0.494 | 50.1% | 0.664 | 12.7 |
| SimpleRNN | 0.400 | 0.423 | 45.9% | 0.796 | 7.4 |
| LSTM | 0.467 | 0.469 | 48.7% | 0.690 | 15.7 |
| GRU | 0.478 | 0.481 | 48.0% | 0.666 | 19.1 |
| BiLSTM | 0.461 | 0.475 | 49.2% | 0.683 | 21.6 |



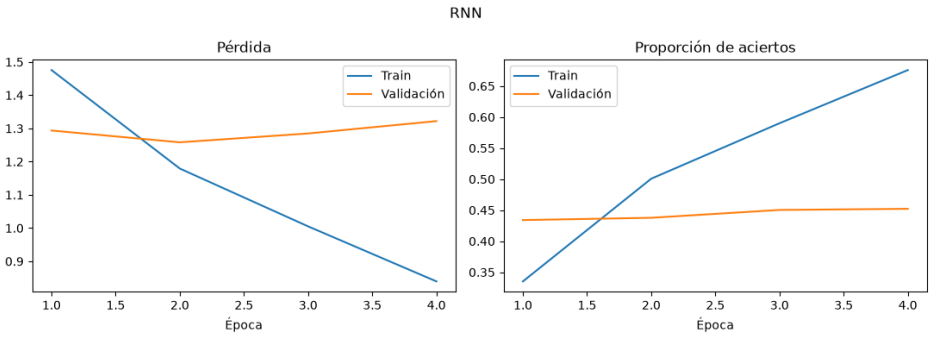

| Modelo | Precision macro | Recall macro | Log loss | Parámetros |
|---|---|---|---|---|
| TF-IDF + RL | 0.492 | 0.501 | 1.190 | 150,005 |
| SimpleRNN | 0.441 | 0.460 | 1.239 | 482,245 |
| LSTM | 0.469 | 0.488 | 1.183 | 488,485 |
| GRU | 0.483 | 0.480 | 1.187 | 486,501 |
| BiLSTM | 0.472 | 0.492 | 1.167 | 496,965 |

La mejor red por F1 en test fue GRU (0.481); el modelo elegido sigue siendo TF-IDF + RL. Elegir otra red después de mirar test rompería el protocolo. Una menor log loss puede coexistir con menor F1: las probabilidades y las etiquetas discretas evalúan aspectos distintos.

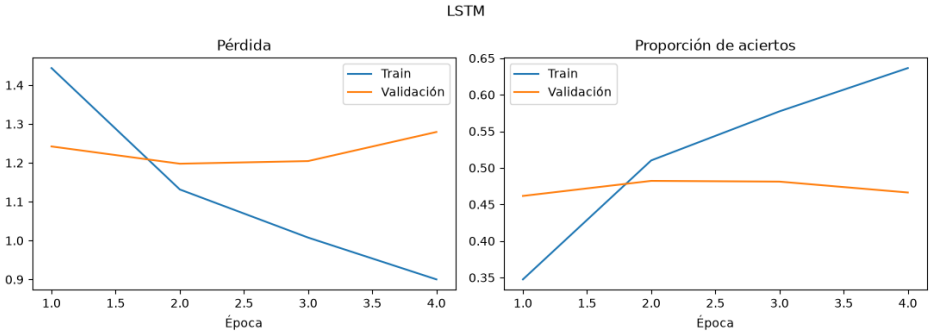
F1 macro da igual peso a cada clase; accuracy exige acertar exactamente la estrella. MAE distingue errores cercanos y extremos. El tiempo corresponde a esta máquina y no a latencia de servicio; TF-IDF incluye dos ajustes. Los parámetros no son una medida completa de memoria. Una semilla no demuestra significación estadística.

# 5. Curvas de aprendizaje y sobreajuste

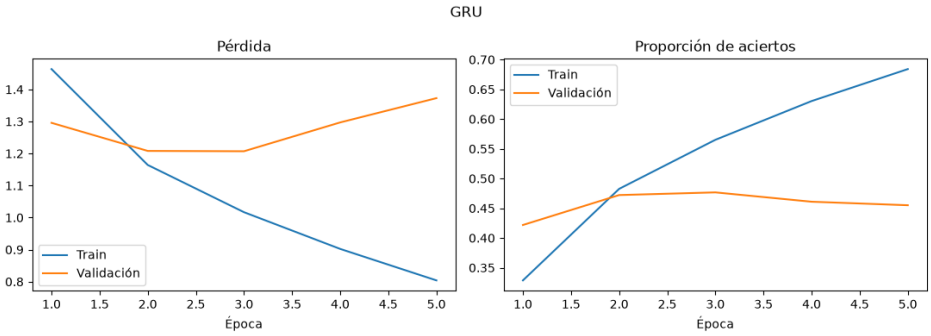
## SimpleRNN · mejor pérdida de validación: época 2 de 4



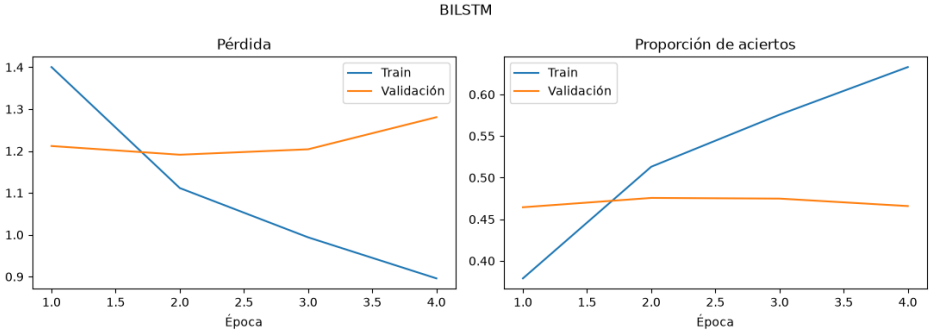

## LSTM · mejor pérdida de validación: época 2 de 4




## GRU · mejor pérdida de validación: época 3 de 5



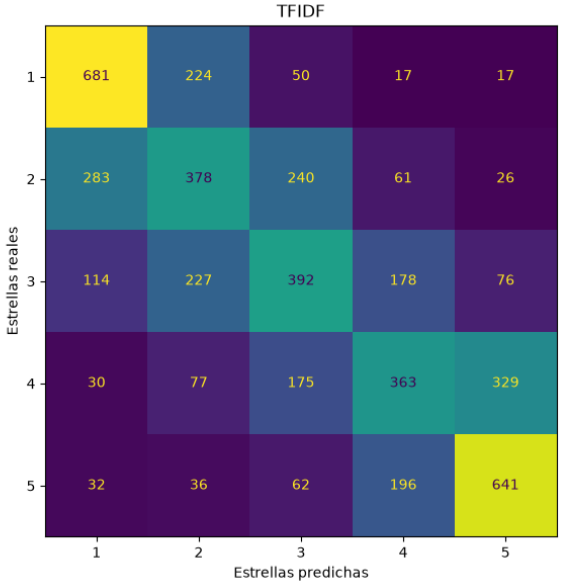

## BiLSTM · mejor pérdida de validación: época 2 de 4




La separación entre train y validación orienta sobre sobreajuste. El último punto no es necesariamente el modelo guardado: se restauran los pesos con menor val_loss. No basta observar que mejora accuracy de train para concluir que mejora la generalización.

# 6. Errores: clases, magnitud y ejemplos reales

La clase con menor F1 es 2 estrellas: 0.392. El 12.2% de test presenta un error de al menos dos estrellas. Son medidas distintas: el promedio puede ocultar clases difíciles y errores costosos.




| Clase | Precision | Recall | F1 | n |
|---|---|---|---|---|
| 1 estrellas | 0.597 | 0.689 | 0.640 | 989 |
| 2 estrellas | 0.401 | 0.383 | 0.392 | 988 |
| 3 estrellas | 0.427 | 0.397 | 0.411 | 987 |
| 4 estrellas | 0.445 | 0.373 | 0.406 | 974 |
| 5 estrellas | 0.589 | 0.663 | 0.624 | 967 |

## Errores graves seleccionados para revisión

**ID es_0417929 · real 5 · predicha 1**
No llegó el paquete, informé al vendedor y tuve respuesta inmediata para darme solución.

**ID es_0392945 · real 1 · predicha 5**
El material no es de muy buena calidad. el pedido tardo mucho ,no estoy muy contento con esta compra,no lo recomiendo

Son casos seleccionados por magnitud y confianza, no una muestra representativa. Conviene revisar contrastes, valoración del vendedor frente al producto y posibles etiquetas ambiguas. Son hipótesis de lectura, no causas demostradas ni categorías anotadas. La probabilidad máxima no está calibrada.

# 7. Robustez: qué se midió y qué no

Se tomó una muestra estratificada de 200 reseñas de test (40 por estrella, semilla 42). El archivo está ordenado por clase: tomar sus primeras filas sesgaría la prueba. Sin reentrenar se aplicaron mayúsculas/espacios, quitar tildes y una transposición interna. Mantener etiquetas es aproximado: algunas modificaciones alteran el sentido. No se agregan datos artificiales al entrenamiento.

| Modelo | Variante | F1 macro | Delta F1 | Cambio clase |
|---|---|---|---|---|
| TF-IDF + RL | original | 0.534 | +0.000 | 0.0% |
| TF-IDF + RL | sin_tildes | 0.528 | -0.006 | 9.5% |
| TF-IDF + RL | una_errata | 0.510 | -0.024 | 10.0% |
| SimpleRNN | original | 0.458 | +0.000 | 0.0% |
| SimpleRNN | sin_tildes | 0.411 | -0.048 | 11.5% |
| SimpleRNN | una_errata | 0.462 | +0.004 | 14.0% |
| LSTM | original | 0.482 | +0.000 | 0.0% |
| LSTM | sin_tildes | 0.465 | -0.017 | 7.0% |
| LSTM | una_errata | 0.438 | -0.043 | 11.0% |
| GRU | original | 0.489 | +0.000 | 0.0% |
| GRU | sin_tildes | 0.488 | -0.001 | 13.5% |
| GRU | una_errata | 0.473 | -0.016 | 15.5% |
| BiLSTM | original | 0.483 | +0.000 | 0.0% |
| BiLSTM | sin_tildes | 0.506 | +0.023 | 6.0% |
| BiLSTM | una_errata | 0.464 | -0.019 | 12.5% |

Mayúsculas/espacios produjeron 0 cambios de clase en los cinco modelos: la limpieza transforma esas versiones en el mismo texto. Esto es un control técnico. La tabla compara cada perturbación con el original de las mismas 200 reseñas, no con las 4.905 de todo test.

En TF-IDF + RL, la menor variación de F1 entre estas dos perturbaciones fue -0.024 en una_errata; cambió la clase del 10.0% de las reseñas. Una variación pequeña no prueba robustez general: la muestra y las transformaciones son limitadas.

# 8. Conclusiones, límites y siguiente experimento

## Subconjuntos del modelo seleccionado

| Segmento | n | Accuracy | MAE |
|---|---|---|---|
| cortas_hasta_20 | 2109 | 49.7% | 0.675 |
| medias_21_a_60 | 2423 | 51.0% | 0.640 |
| largas_mas_60 | 373 | 45.6% | 0.751 |
| con_negacion | 2605 | 50.1% | 0.671 |
| menciona_estrellas | 108 | 63.9% | 0.463 |

Los grupos se superponen y pueden tener distribuciones de clases distintas. Sus diferencias no demuestran causalidad. No hay información de canal, cliente o producto.

## Qué permite concluir esta ejecución

1. TF-IDF + RL es la referencia seleccionada con validación. Su F1 en test es 0.494. La complejidad recurrente no se justifica automáticamente por el número de capas o parámetros; hay que observar calidad y costo.

2. La clase 2 estrellas tiene el menor F1. El MAE de 0.664 y la tasa de errores de dos o más estrellas añaden información que accuracy no muestra.

3. Vocabulario y longitud son decisiones medibles: OOV pierde identidad léxica, el truncamiento pierde contenido y PAD exige máscara. Los controles del notebook hacen visible cada operación.

4. Los controles de relleno y normalización verifican consistencia técnica. Las perturbaciones son una prueba exploratoria limitada; no validan otro dominio ni prueban que el modelo comprenda ironía.

## Qué haríamos antes de usarlo fuera del laboratorio

Conseguir una prueba externa con producto, autor y fecha; separar por esas unidades cuando sea pertinente; repetir semillas y estimar incertidumbre; analizar ejemplos ambiguos excluidos; calibrar probabilidades y acordar costos de error. Comparar vocabularios, longitudes o modelos preentrenados con validación. Reservar una nueva prueba para el experimento siguiente, porque esta ya fue inspeccionada.

## Uso posible

Apoyar la exploración de opiniones o sugerir una calificación para reseñas que no la tengan. En este corpus las estrellas ya existen: el valor de la Sesión 3 es aprender a estimarlas a partir del lenguaje y detectar limitaciones. No identifica automáticamente la razón de una queja y no se proponen umbrales de automatización sin evidencia.

# 9. Reproducibilidad y fuentes

Repositorio: nfmanios-debug/ean_nlp
Notebook autónomo en Colab

La ejecución local completa genera métricas, predicciones, auditoría, vocabulario, curvas y modelos en amazon_reviews_es/. Los documentos reflejan la ejecución de esta entrega; al volver a ejecutar pueden cambiar tiempos y cifras. Colab está preparado, pero la comprobación realizada fue local.

Dataset real y procedencia
Keras: TextVectorization
TensorFlow: masking y padding
Keras: Embedding
Keras: SimpleRNN

Adaptación de la estructura del paquete Entrega Amazon de la Sesión 2. No se trasladaron sus cifras, tareas, conclusiones ni umbrales al caso de Amazon.