Pitch · Amazon Reviews y redes recurrentes

Guion de 5-6 minutos · Sesión 3 PLN

Reparto propuesto a partir de la entrega de referencia; los roles se pueden intercambiar.

Tiempo	Diapositivas	Voz y responsabilidad
0:00-0:40	1-2	Nelsón Fabian Manios · Gerencia IA
0:40-1:30	2-3	Sebastian Padilla Castaño · Ciencia de Datos
1:30-2:45	4-6	Juan David Gonzalez · Especialista ML
2:45-3:35	7-8	Juan David Gonzalez · Comparación y curvas
3:35-4:35	9-10	Sebastian Padilla Castaño · Errores y robustez
4:35-5:30	11-12	Nelsón Fabian Manios · Decisión y cierre

1. El problema · Gerencia IA

Nuestro reto es estimar la satisfacción leyendo una reseña real de Amazon en español. La respuesta que aprendemos es la calificación de una a cinco estrellas. No tenemos etiquetas de causas o emociones: una reseña puede elogiar el producto y criticar la entrega. Comparamos una referencia TF-IDF con cuatro redes recurrentes para preguntar si conservar el orden mejora lo suficiente la predicción como para justificar su costo.

2. Auditoría · Ciencia de Datos

La fuente publica 200.000 reseñas de entrenamiento y 5.000 para validación y prueba. Antes de entrenar verificamos origen, esquema, etiquetas, vacíos y duplicados. Retiramos 2,573 filas contradictorias y 671 copias adicionales. Usamos 20.000 para entrenar y 4.905 en cada conjunto restante. Aprendemos vocabulario solo de train, elegimos con validación y dejamos test para el final. La limpieza cambia el benchmark y no podemos separar por producto o autor porque no tenemos esos campos.

3. Cómo lee la red · Especialista ML

Cada palabra se convierte en un ID. El cero es PAD: espacio vacío. El uno es OOV: una palabra real que no tiene entrada propia. Las demás tienen su índice. Usamos hasta 15.000 posiciones y secuencias de 72 tokens. Padding completa las cortas; truncamiento recorta las largas y puede borrar una queja al final. La máscara hace que la red ignore PAD, pero no OOV. El embedding convierte cada ID en 32 valores que se aprenden con las reseñas. SimpleRNN actualiza una memoria; LSTM y GRU añaden compuertas, y BiLSTM lee en ambos sentidos. Todas producen una calificación por reseña: el patrón es many-to-one. Las cinco probabilidades son clases alternativas, no cinco pasos de salida.

4. Resultados · Especialista ML

La elección por F1 macro de validación fue TF-IDF + RL. En test obtuvo F1 0.494 y accuracy 50.1%. La mejor red por F1 de test fue GRU, con 0.481; esto no cambia la elección previa. También comparamos precisión, recall, log loss, error en estrellas, tiempos y parámetros. Las curvas permiten ver si la mejora de train deja de acompañarse de mejora en validación. La parada temprana recupera los pesos de menor pérdida; no necesariamente los de la última época.

5. Errores y robustez · Ciencia de Datos

El promedio no basta. La clase con menor F1 fue 2 estrellas, y el 12.2% de test tuvo errores de al menos dos estrellas. Mostramos casos reales graves para discutirlos, sin afirmar causas que no están anotadas. En 200 reseñas probamos espacios y mayúsculas, ausencia de tildes y una errata. La normalización conservó las predicciones; las otras pruebas miden sensibilidad limitada. Quitar tildes puede cambiar significado, por lo que mantener la etiqueta es una aproximación. Agregar PAD tampoco cambió las salidas de las cuatro redes: es un control de implementación.

6. Decisión · Gerencia IA

Conservamos la referencia elegida por validación para este laboratorio. No afirmamos que una red o TF-IDF gane siempre. Una semilla, una muestra y un presupuesto no demuestran superioridad estadística. Para usarlo fuera del ejercicio necesitamos otra prueba con productos y periodos nuevos, repetir semillas, revisar errores costosos y calibrar probabilidades. El resultado de esta sesión es una comparación reproducible que explica cómo el lenguaje se convierte en una secuencia, qué información se pierde y por qué una métrica debe leerse junto con sus errores.

Preguntas para la exposición

Pregunta	Respuesta breve
¿PAD y OOV son lo mismo?	No. PAD es ausencia; OOV es contenido desconocido que se procesa.
¿Por qué no todas las palabras?	Presupuesto de memoria/tiempo y estimación de términos raros; medimos la pérdida de cobertura y texto.
¿Es many-to-many?	No. Una secuencia produce una calificación: many-to-one.
¿Por qué una red no gana necesariamente?	Aprende también sus embeddings desde cero con una muestra y presupuesto limitados. Es una hipótesis explicativa, no causalidad demostrada.
¿Se puede automatizar ya?	La prueba no lo acredita: faltan evaluación externa, costos de error y calibración.