SESIÓN 3 · PLN

Amazon Reviews: palabras, memoria y calificaciones

¿Qué aporta una red recurrente frente a TF-IDF para predecir de 1 a 5 estrellas?

Datos reales · Notebook autónomo · Comparación de cinco modelos

Juan David Gonzalez · Nelsón Fabian Manios · Sebastian Padilla Castaño

Datos y auditoría antes de entrenar

Conjunto	Original	Usado
Train	200.000	20.000
Validación	5.000	4.905
Test	5.000	4.905

Se excluyeron 2,573 filas contradictorias y 671 copias adicionales. Origen y hashes verificados; no hay cruces exactos de IDs/textos.

La limpieza cambia el benchmark. No hay IDs de autor/producto: no garantizamos independencia por esas unidades.

Vocabulario: qué palabras puede distinguir

15.000 posiciones = PAD + OOV + hasta 14.998 palabras

ID	Significado	Tratamiento
0 · PAD	No hay palabra	Se omite con máscara
1 · OOV	Palabra sin entrada propia	Se procesa con vector compartido
2 en adelante	Palabra conocida de train	Embedding propio

Solo train aprende el vocabulario. Limitarlo reduce pesos; la contrapartida es perder identidad de palabras raras. No borramos negaciones.

Padding completa; truncamiento elimina contenido

Longitud L = 72 tokens · percentil 95 de train, limitado a 16-96

Reseña corta → palabras + PAD al final
Reseña larga → primeros L tokens; el final se descarta

Masking: False en PAD; True en palabras conocidas y OOV. Añadir siete PAD conservó la salida de las cuatro redes (tolerancia 1e-5).

Test: 4.75% de reseñas truncadas; 5.83% de tokens descartados. Puede perderse una queja al final.

Embeddings entrenables y salida many-to-one

Texto → IDs (B,L) → vectores (B,L,32) → estado de la reseña → probabilidades (B,5)

La tabla de embeddings aprende con la pérdida. No viene preentrenada y sus 32 dimensiones no son emociones nombradas.

Patrón	Salida	Aquí
Many-to-one	Una calificación por reseña	Sí
Many-to-many alineado	Una etiqueta por palabra	No
Sequence-to-sequence	Una secuencia generada	No

SimpleRNN, LSTM, GRU y BiLSTM

Modelo	Memoria	Compromiso
SimpleRNN	Estado tanh, pesos compartidos	Puede perder contexto distante
LSTM	Celda y tres compuertas	Más componentes para regular memoria
GRU	Actualización y reinicio	Alternativa más compacta a LSTM
BiLSTM	Dos LSTM en sentidos opuestos	Usa texto completo; mayor costo

Mismo corpus y presupuesto recurrente: embeddings 32, unidades 32, dropout 0,25, hasta ocho épocas. TF-IDF usa palabras y bigramas + regresión logística.

La complejidad no garantiza una mejora; se selecciona por F1 macro de validación.

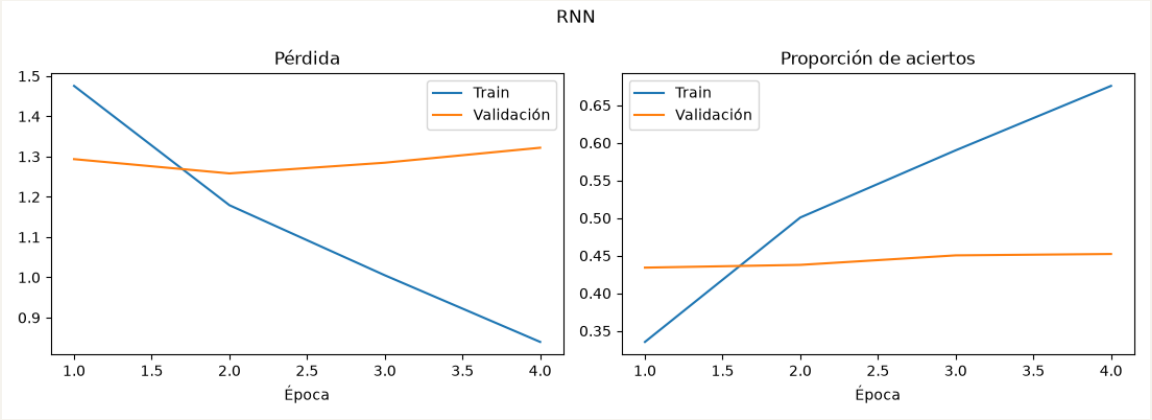
Comparación observada de los cinco modelos

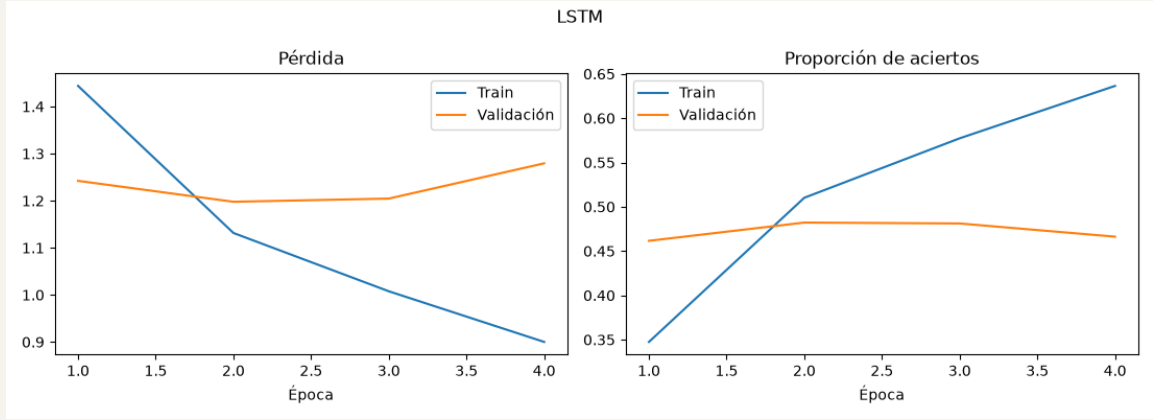
Modelo	F1 val.	F1 test	Accuracy	Tiempo (s)
TF-IDF + RL	0.479	0.494	50.1%	12.7
SimpleRNN	0.400	0.423	45.9%	7.4
LSTM	0.467	0.469	48.7%	15.7
GRU	0.478	0.481	48.0%	19.1
BiLSTM	0.461	0.475	49.2%	21.6

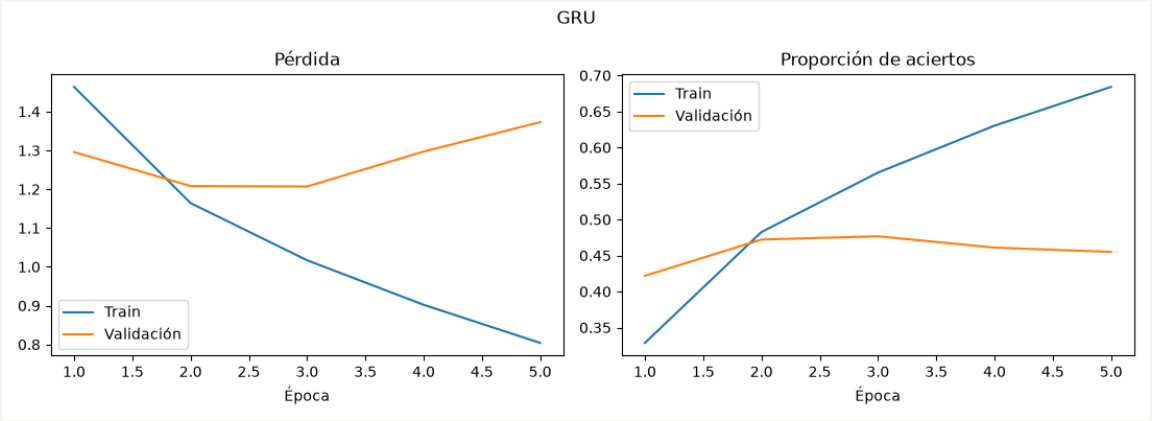
Seleccionado por validación: TF-IDF + RL. Mejor red por F1 test: GRU (0.481). Test no modifica la elección.

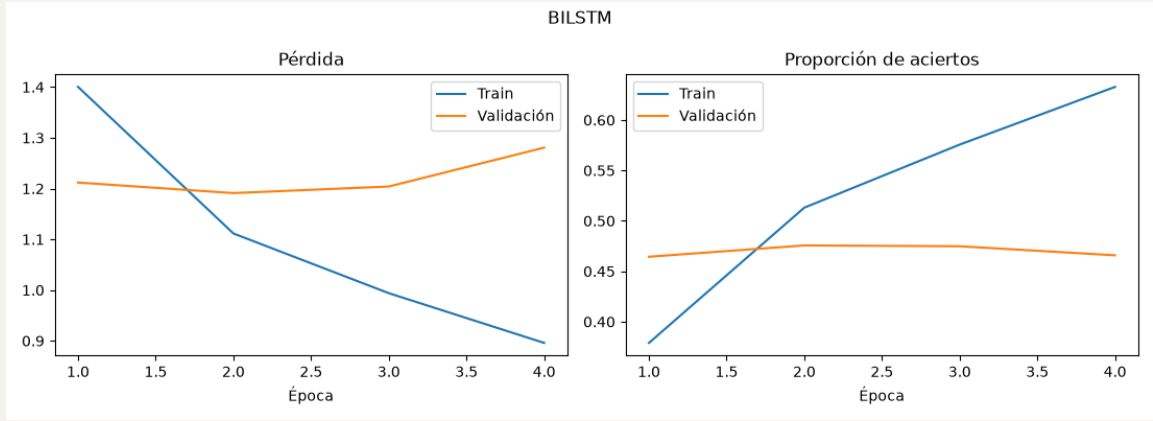
Una ejecución y una semilla. Los tiempos dependen del equipo y no son latencia de inferencia.

Las curvas muestran cuándo deja de generalizar



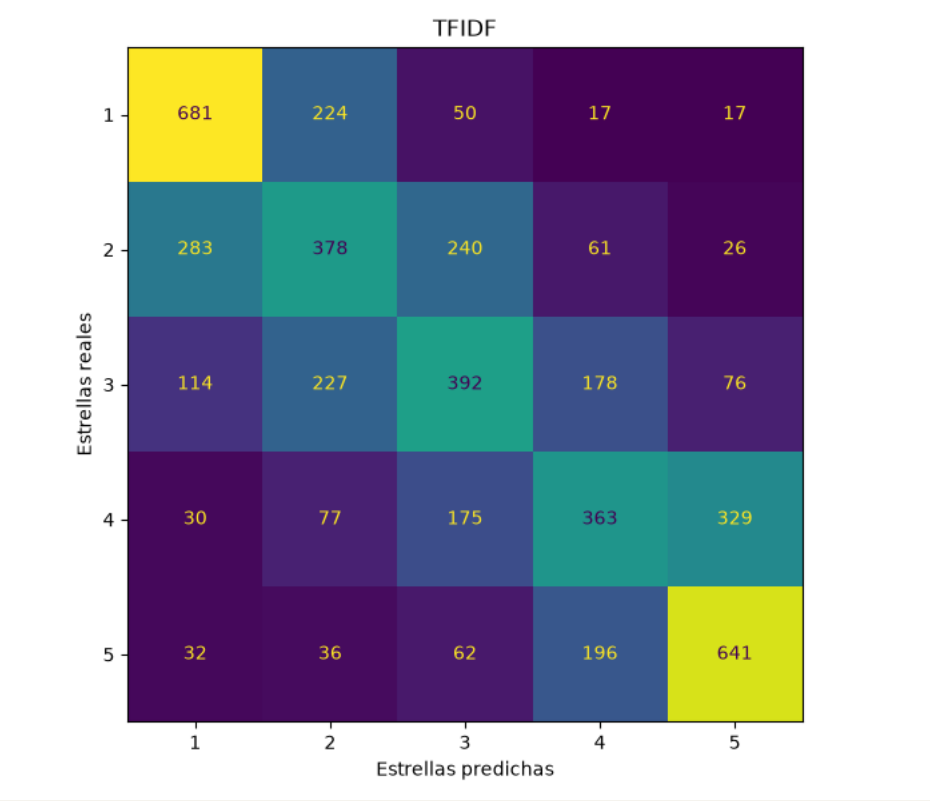






Parada temprana: se recupera la menor pérdida de validación, no la última época.

Errores: el promedio no cuenta toda la historia



Clase con menor F1:
2 estrellas · 0.392

12.2% de test tiene un error de dos o más estrellas.
MAE: **0.664** estrellas.

Revisar contrastes y etiquetas ambiguas como hipótesis. Los casos graves ilustran fallos; no representan todos los errores.

Robustez sobre 200 reseñas reales modificadas

Prueba de TF-IDF + RL	F1 macro	Delta F1	Cambio de clase
original	0.534	+0.000	0.0%
mayusculas_espacios	0.534	+0.000	0.0%
sin_tildes	0.528	-0.006	9.5%
una_errata	0.510	-0.024	10.0%

Mayúsculas/espacios es un control del limpiador. Tildes y erratas miden sensibilidad limitada; mantener las estrellas es una aproximación.

No se reentrena ni se elige otro modelo. No equivale a una validación externa.

Alcance de las conclusiones

01 Una estrella resume una opinión imperfectamente

No hay causas de queja, anotaciones de ironía ni etiquetas políticas.

02 La prueba ya fue inspeccionada

Otro ajuste requeriría validación y una nueva prueba reservada.

03 Faltan evidencias de generalización

Repetir semillas; evaluar nuevos productos/periodos; calibrar probabilidades y revisar errores costosos.

Conclusión y siguiente experimento

TF-IDF + RL queda como referencia del laboratorio: F1 0.494 y accuracy 50.1% en test.

El aporte de la Sesión 3: entender la secuencia, cuantificar qué información se pierde y evaluar memoria recurrente frente a un baseline.

Siguiente paso: nueva prueba externa, sensibilidad a longitud/vocabulario en validación y repetición de semillas. Uso asistido antes de asumir automatización.

Código y fuentes: github.com/nfmanios-debug/ean_nlp · dataset SetFit/amazon_reviews_multi_es